

Подбор гиперпараметров модели

**Random Forest для предсказания
употребления алкоголя студентами**

Штыхно Илья

Группа: М8О-309Б

Датасет: Student Alcohol Consumption

Описание задачи

Цель

Предсказать уровень употребления алкоголя студентами на основе социально-демографических факторов

Тип задачи

Бинарная классификация

Низкий (0) / Высокий уровень (1)

Выбранная модель: Random Forest

- ✓ Работает с разными типами признаков
- ✓ Устойчив к переобучению
- ✓ Оценивает важность признаков
- ✓ Множество гиперпараметров

Целевая переменная

Среднее употребление = (будни + выходные) / 2

Порог: среднее > 2 → высокий уровень

Гиперпараметры Random Forest

n_estimators

Количество деревьев

50, 100, 200, 300, 500

max_depth

Макс. глубина дерева

5, 10, 15, 20, None

min_samples_split

Мин. образцов для split

2, 5, 10, 15

min_samples_leaf

Мин. образцов в листе

1, 2, 4, 8

max_features

Число признаков

'sqrt', 'log2', None

criterion

Функция оценки

'gini', 'entropy'

bootstrap

Bootstrap выборки

True, False

class_weight

Веса классов

None, 'balanced'

⚡ Найти оптимальную комбинацию для максимальной точности

Данные и подготовка

395

студентов

33

признака

80/20

train/test

Категории признаков

Демографические

Пол, возраст, адрес

Родители

Образование, профессия

Академические

Учёба, пропуски

Социальные

Время, отношения



Предобработка

✓ Label Encoding

Категории → числа

✓ Целевая переменная

avg = (Dalc + Walc) / 2

✓ Stratified Split

Пропорции классов

Дисбаланс: 76% low / 24% high

Методы подбора гиперпараметров

1 Grid Search

Полный перебор всех комбинаций

- ✓ Гарантированно находит лучшие параметры
- ✓ Детерминированный результат
- ✗ Медленный для большого пространства

Перебрано 432 комбинации с 5-fold CV

2 Random Search

Случайная выборка комбинаций

- ✓ Быстрее Grid Search
- ✓ Хорошо исследует пространство
- ✗ Не гарантирует оптимум

Проверено 100 случайных комбинаций

3 Optuna

Байесовская оптимизация

- ✓ Самый эффективный метод
- ✓ Учится на предыдущих попытках
- ✓ Адаптивный подход

Испытано 100 комбинаций

Метрика оптимизации

F1-score с 5-Fold Cross-Validation на тренировочной выборке

Сравнение результатов

Grid Search 🏆

F1 (CV)

0.4820

Test Accuracy: 0.7722

F1: 0.5000

Random Search

F1 (CV)

0.5398

Test Accuracy: 0.7848

F1: 0.4848

Optuna

F1 (CV)

0.5433

Test Accuracy: 0.7848

F1: 0.4848

Лучшие параметры (Grid Search)

`n_estimators: 100`

`max_depth: 15`

`min_samples_split: 5`

`min_samples_leaf: 1`

Ключевые выводы

- ✓ Grid Search - лучший Test F1-score
- ✓ Optuna - лучший CV F1-score
- ✓ Random Search/Optuna - лучший Test Accuracy
- ✓ Компромисс между метриками

Интерпретация моделей

Понимание, КАК и ПОЧЕМУ модель принимает решения

LIME

Local Interpretable Model-agnostic Explanations

Локальная интерпретация

Объясняет конкретное предсказание

Как работает

Создаёт простую линейную модель вокруг конкретной точки данных

Показывает

Какие признаки повлияли на решение и насколько (вклад в ±)

Пример: "Студент предсказан как высокий риск, потому что failures=3 (+0.15) и goout=4 (+0.12)"

SHAP

SHapley Additive exPlanations

Глобальная интерпретация

Объясняет поведение модели в целом

Как работает

Использует теорию игр для справедливого распределения вклада

Показывает

Важность признаков для всего датасета и взаимодействия

Пример: "В среднем failures самый важный признак (impact 0.21), затем goout (0.15)"

LIME: Локальная интерпретация

Студент #0 (тестовая выборка)

Истинный класс: Низкий

Предсказание: Низкий ✓

Вероятность "Высокий":

16.69%

Факторы ЗА низкий уровень

sex ≤ 0 (женский пол)

Вес: -0.1026

absences ≤ 0 (нет пропусков)

Вес: -0.0436

health ≤ 3

Вес: -0.0291

Факторы ПРОТИВ

goout > 4 (часто гуляет)

Вес: +0.1133

famrel ≤ 4

Вес: +0.0380

SHAP: Глобальная важность признаков

Средняя абсолютная важность признаков на всей тестовой выборке

1. goout

выходы с друзьями




2. sex

пол студента



3. studytime

время на учебу




4. G3

финальная оценка



5. absences

пропуски занятий



Ключевые инсайты

✓ Goout - главный предиктор ✓ Sex - второй по важности ✓ Studytime/G3 важны

Интерактивный калькулятор

Функции

Ввод данных

Индекс студента (0-78)

Предсказание

Класс + вероятности

LIME объяснение

Топ-10 признаков

SHAP график

Вклад признаков

Примеры

Студент #0

Низкий риск - 77%

Студент #5

Высокий риск - 83%

Студент #15

Пограничный - 51%

Выводы и результаты

Достигнутые цели

✓ Random Forest модель

8 гиперпараметров

✓ 3 метода сравнены

Grid/Random/Optuna

✓ Датасет подготовлен

395 студентов, 31 признак

✓ Интерпретация

LIME + SHAP

Лучший по F1

Grid Search

0.5000

Test F1-score

Accuracy: 77.22%

Optuna - лучший CV

F1 на кросс-валидации

0.5433

Test Accuracy: 78.48%